DCLAB R&D · PROJECT AND PRODUCT

Recap: from research repository to an ML Intern with proof

Everything we discussed and built, from the first cleanup of the repository to the redesigned clickable demo of the final product. English first, then a Persian summary and a Persian walkthrough of the demo.

Repository: Shahriyar-Moradi/Research_Development_DCLab · latest commit `1cf5ae5` on main · updated 5 October 2026

Note: in this document, "DCLab" means the DCLab R&D project and the product growing out of it, not DCLab's main product.

1. The vision in one paragraph

DCLab R&D is becoming an **"ML Intern" for most kinds of machine-learning work**, close to Hugging Face's ML Intern, with one difference: every step comes with proof. It writes the prediction contract before looking at any score, catches leakage, uses the holdout once, and cites measured evidence for each suggestion ("someone hit this before, here is the number"). The guiding design rule from your earlier chats: **the LLM is the decision-maker inside a controlled graph, not the owner of the graph.**

The six layers of the idea

Layer	What it means
1. Evidence engine (the R&D)	Experiments on real data (Kaggle, Hugging Face, UCI) become rules and records the product can cite: 579 experiments, 22 rules, leakage precedents, measured pitfalls.
2. Workflow engine	Ten fixed steps WF-01…WF-10: contract → source → split → train-only EDA → leakage audit → feature ladder → algorithm screen → conservative tuning → reliability → knowledge capture. Allowed moves are explicit; code validates every move; every move is logged.
3. Agent surfaces	The agentic notebook (proof beside each cell), the intern (give a task, it works inside a budget), Hugging Face Chat UI / ML Intern over MCP, later a VS Code companion.
4. A focused small model	A fine-tuned open model (7–9B first) that knows the next step, when to stop and when to ask. Not a general chatbot. "Macro-tokens" (your "cake" idea: two steps for ~200 tokens instead of 400) stay a research question.
5. Cost efficiency	A cost ladder: typed classifier (Jev) → NOOA structured call → full LLM only when needed; pass references, not growing message history.
6. Domain packs	One engine, many packs: tabular first, then time series, text, vision and driving (ODD as the contract), maps and road flow, scene graphs, and software bug-fixing as the first non-ML pack.

2. What we did, in order

Round	What you asked	What was built
Clean and structure	"Clean and structure the repo", one folder per research idea, work on main and keep dev fast-forwarded.	Top-level folders by role (data, research, evidence, code); every research idea has the same shape and a generated INDEX.md; a Research map; duplicates, dead files and regenerable models removed; `make clean`.
Product redesign	"Agentic DCLab notebook … build any type of ML model in any industry in an agentic way instead of code."	The **DCLab notebook** (`dclab_rnd/studio`): projects, data upload or 16 studied samples, a prediction contract with forbidden columns and proof, five deterministic stages (data, leakage, features, models, final), evidence-cited notes, runnable .ipynb export.
Fill the gaps	Kaggle/HF data; multiclass, time series, imbalanced fraud, text+tabular; paired instructions; an SFT job; an outside-reader narrative. "Do not remove anything; the goal is improvement."	Expansion campaign on 4 new task types (fraud, letters, bike demand, reviews), SFT v3 corpus (326 examples), `train_lora.py` / `eval_sft.py`, project-derived training examples, an outside-reader narrative.
The intern	"Something like Hugging Face ML Intern, locally, one click away."	The **DCLab intern** (`dclab_rnd/intern`): task → plan → tool calls → report, 18 tools, enforced budget, a deterministic standard plan when no model is configured; works with any OpenAI-compatible endpoint (HF router, Ollama, OpenAI).
Chat UI and ML Intern	"Use github chat-ui and ml-intern in DCLab."	DCLab as an **MCP server** at `/mcp`; `make chat-ui` and `make chat-ui-intern` run Hugging Face Chat UI locally with DCLab attached. Verified end to end: 18 DCLab tools in plain mode, 32 tools in ML Intern mode.
Your background	Two PDFs of earlier chats (43 questions, 69 messages) to give full context.	A full review: the six layers, the 10 workflow blocks, the 22 rules, the controlled-graph architecture, domain packs, the workflow-policy model, and a prioritized MVP roadmap.
Final product demo	"Generate a full HTML demo of the final product … to understand what we miss, need and don't need."	A **19-page clickable demo** with 4 role views, guided tours, a **Blueprint layer** marking 151 features, and a Must / Later / Cut decision board. Published privately and committed as `docs/product-demo/` (`make product-demo`, checked by `make rd-check`).
Move to local	"Switch the cloud environment to my local one."	Explained teleport (`claude --teleport session_01VD8xcoYNb4YJEpXWRz2oU3`) and Remote Control (`/remote-control`); all branches pushed and aligned at `4865ead`.
Category-code bug fix	The fix task suggested while building the	Commit `1cf5ae5`: factorized category codes no longer enter log, ratio, product, interaction or binning features (rule DCLAB-

	demo.	R11). The declared categorical columns are the source of truth; `tests/test_category_codes.py` covers it. Old results stay as recorded; `evidence/README.md` lists the affected records.
Demo redesign	"The demo is crowded and hard to understand … make it clean and move details into tabs on the top."	New design system (cool grey, white cards, green actions, Inter and JetBrains Mono). The sidebar is regrouped as Workspace, Project, Knowledge and Platform. Every page opens on an **Overview** with four headline numbers and one main card, and the details live in tabs at the top of the page. Tours and the Blueprint layer open the right tab by themselves; ⌘K finds tabs. The published copy is updated; the source change is not committed yet.

3. Where the repository stands

579
experiments in the registry · 483 eligible · 11 datasets

133
evidence records: 22 rules, 10 workflow blocks, 70 experiments, 6 leakage precedents, 6 pitfalls

326
SFT v3 examples (260 train · 66 validation)

110
tests in the working copy · 108 pass, 2 fail (see section 7)

Piece	Status	Where
Evidence engine (registry, index, rules, field guide)	Built	`dclab_rnd/evidence_index.py`, `evidence/`
DCLab notebook (five stages, contract, export)	Built (tabular)	`dclab_rnd/studio/`
Intern (tools + budget, standard plan)	Built	`dclab_rnd/intern/`
MCP endpoint + Chat UI / ML Intern	Built, tested	`dclab_rnd/mcp_server.py`, `scripts/chat_ui.py`
Notebook copilot review	Built (CLI)	`python -m dclab_rnd.copilot review`
Training data for the small model	Data ready, no run yet	`research/llm-fine-tuning/`
Workflow graph with validator and logged moves	Partial	stages run in order; explicit graph not yet
Judgment benchmark	Partial	notebook pilot 6/7; blind auditor 11/18 leaks
Real code execution, GPU jobs	Missing	reachable only through Chat UI's ML Intern mode
Product demo (19 pages, Blueprint, decisions)	Built, redesigned	`docs/product-demo/`
Vision, driving, maps, scene-graph packs	Proposals	`research/` tracks with 0 experiments

4. Real findings worth remembering

- **Leakage is the largest lie.** Bank marketing `duration`: training-CV ROC-AUC 0.7130 without it, 0.8972 with it (+0.1842). HyperAck final fares: 0.9455 safe vs 0.9802 unsafe. PageValues: +0.1968.
- **A real holdout, used once.** Term-deposit model (extra_trees C02): ROC-AUC 0.7718, 95% interval 0.7126–0.8290, Brier 0.0870, ECE 0.0272.
- **The copilot on a leaky notebook.** The teammate notebook prints accuracy 0.9689. After the copilot's fixes, the honest result on 9,043 untouched rows is ROC-AUC 0.7577 (AP 0.3454). Both were measured by running the code.
- **Measured pitfalls.** Oversampling before the split: up to +0.3003 ROC-AUC of pure inflation. Target-encoding an ID: 1.0000 reported vs 0.8160 honest. Choosing by holdout score: +0.0072 optimism on average.
- **No universal best algorithm.** LightGBM had the best mean rank (2.55) but won only 3 of 11 datasets; logistic regression won the Telco churn campaign (0.8499).
- **The critic gate works.** 147 LLM critic challenges kept, 10 dropped because the numbers contradicted them.
- **A real bug, found by the demo and now fixed.** The pipeline took the log of factorized category codes (`log1p_month`, `log1p_poutcome` were top features in EXP-010). Fixed in `1cf5ae5`. An informal paired re-check on identical training folds (no holdout, nothing saved as a result) shows the derived recipes' lift came from arithmetic on codes: without it, bank_marketing `ratios` loses 0.016 ROC-AUC and german_credit `interactions` 0.021, so both would pick `raw`.

5. The product demo and the Blueprint

The demo shows the final product as if it were finished, so we can decide what to build. After the redesign every page opens on an **Overview** (four headline numbers and one main card) and keeps its details in tabs at the top. Groups in the sidebar:

Group	Pages
Workspace	Home · New project · Intern · Compute & jobs
Project · Term deposits	Workflow · Contract & data · Notebook · Leakage & features · Models · Reliability · Decision brief (English/Persian)
Knowledge	Evidence library (searches the 133 real records) · Research lab · Benchmark · Policy model
Platform	Domain packs · Integrations · Admin · Blueprint & roadmap (gap map, roadmap, non-goals, Must / Later / Cut decisions)

The top bar holds breadcrumbs, search (⌘K), the "View as" menu (developer, business, researcher, admin) and the theme switch. The Blueprint layer and the guided tours sit at the bottom of the sidebar.

151	51	46	48	6
features in the demo	built today	partly built	to build	need research

> Open it: `docs/product-demo/index.html` (no server needed) or the private published copy at claude.ai/artifact/Vky86ZeEg2z5gqeapBXwtr, where your decisions save to a shared store Claude can read. The published copy shows the redesign. No decisions are saved yet (checked 5 October).

6. Roadmap toward the MVP

Phase	Goal	Done when
P1 · Proof core	Make every move checkable: the workflow graph, the validator, the transition log, questions and approvals, the business brief, the production gate, the first benchmark suites.	Term-deposit calls and HyperAck run end to end inside the graph; suites A–D score the standard plan and one LLM.
P2 · Reach	Code in a sandbox, live notebook cells with one-click fixes, GPU jobs, data connectors, VS Code companion, roles.	A new project from Kaggle or a warehouse runs with code cells; a GPU job runs under a cap.
P3 · Domain packs	Vision first (pedestrians at night and in rain, split by drive), then time series and text; the pack builder.	The pedestrian experiment runs the ten steps with drive-level splits and slice reports.
P4 · Own model	Graph trajectories → expert labels → QLoRA training → benchmark gates → serve as the intern's model; cost ladder tier 1.	The policy model passes the gates and serves 10% of intern sessions.
R · Research	Macro-actions, maps, scene graphs, driving, software pack, TabPFN rerun.	Each idea has a controlled experiment and a record in the index.

Non-goals (what we will not build)

- A general chatbot, or one giant generic agent.
- A model that owns splits, metrics or selection rules (code owns them).
- "Production-ready" labels from benchmark scores alone.
- Silent deletion of unclear columns, or training on users' projects without opt-in.

7. Open items and next steps

- **Your decisions:** walk through the demo and mark Must / Later / Cut on the Blueprint page; they become the build plan.
- **Owner worksheet:** HyperAck prediction moment (order creation, courier offer, or after assignment) and Telco churn outcome window (30 or 90 days). Also: is `campaign` counted before the call being predicted?
- **First build step:** the workflow graph with its validator and transition log (P1). Everything else depends on it.
- **Commit the demo redesign:** the new `docs/product-demo/` sources are ready but not committed, because `make rd-check` does not fully pass yet.
- **Two failing tests:** `test_intern` (`test_sessions_over_http`: an intern session over HTTP ends as "failed") was already failing before the redesign. `test_research_map` (generated files are stale) follows from uncommitted edits to `dclab_rnd/research_map.py` and other files that another session is still making after the category-code fix; finish that work and rerun `make research-index`.

- **Local work:** the session was teleported to your computer; run `/remote-control` there to continue from the Claude app. Local setup: `python3 -m venv .venv`, install `requirements/base.txt`, add `.env`, then `make rd-check` and `make notebook`.

خلاصه به فارسی

چشم‌انداز. DCLab R&D در حال تبدیل شدن به یک «ML Intern» برای بیشتر کارهای یادگیری ماشین است، شبیه ML Intern هاگینگ‌فیس، با یک تفاوت مهم: هر قدم همراه با مدرک است. اول قرارداد پیش‌بینی نوشته می‌شود، نشت داده پیدا می‌شود، holdout فقط یک بار استفاده می‌شود و هر پیشنهاد به شواهد اندازه‌گیری‌شده استناد می‌کند. اصل طراحی: مدل زبانی داخل یک گراف کنترل‌شده تصمیم می‌گیرد، اما صاحب گراف نیست.

کارهایی که به ترتیب انجام دادیم:

- مخزن را تمیز و ساختارمند کردیم: هر ایده‌ی پژوهشی یک پوشه با شکل یکسان، نقشه‌ی پژوهش، حذف فایل‌های اضافی.
- نوت‌بوک DCLab را ساختیم: پروژه، داده، قرارداد پیش‌بینی، پنج مرحله‌ی قطعی، یادداشت‌های مستند و خروجی نوت‌بوک ژوپیتر (ipynb).
- شکاف‌ها را پر کردیم: داده‌های Kaggle و هاگینگ‌فیس، تقلب، چندکلاسه، سری زمانی، متن، ۳۲۶ نمونه‌ی آموزشی SFT و اسکریپت آموزش LoRA.
- اینترن DCLab را ساختیم: کار را می‌دهید، با ۱۸ ابزار و بودجه‌ی مشخص انجام می‌دهد و گزارش می‌دهد.
- DCLab را به‌صورت سرور MCP به Chat UI و حالت ML Intern هاگینگ‌فیس وصل کردیم و سرتاسر تست کردیم.
- دو PDF گفت‌وگوهای قبلی شما را کامل مرور کردیم و نقشه‌ی راه MVP را نوشتیم.
- دموی قابل‌کلیک محصول نهایی را ساختیم: ۱۹ صفحه، ۴ نمای کاربری، تورهای راهنما و لایه‌ی Blueprint با ۱۵۱ قابلیت (۵۱ ساخته‌شده، ۴۶ نیمه‌کاره، ۴۸ برای ساخت، ۶ نیازمند پژوهش).
- راه انتقال جلسه به کامپیوتر شما را با teleport و Remote Control توضیح دادیم و همه‌ی branchها را هم‌سطح کردیم.
- باگ کدهای دسته‌ای را رفع کردیم (commit `1cf5ae5`): دیگر از کدهای عددیِ دسته‌ها لگاریتم، نسبت یا ضرب ساخته نمی‌شود.
- دمو را از نو طراحی کردیم: هر صفحه با یک «Overview» ساده باز می‌شود و جزئیات در تب‌های بالای صفحه است؛ نسخه‌ی منتشرشده هم به‌روز شد.

یافته‌های واقعی مهم: نشت ستون duration امتیاز را از ۰٫۷۱۳۰ به ۰٫۸۹۷۲ می‌رساند؛ امتیاز صادقانه‌ی مدل روی holdout برابر ۰٫۷۷۱۸ است (بازه‌ی ۰٫۷۱۲۶ تا ۰٫۸۲۹۰)؛ نوت‌بوک دارای نشت دقت ۰٫۹۶۸۹ گزارش می‌کند در حالی که امتیاز واقعی بعد از اصلاح ۰٫۷۵۷۷ است؛ و باگ لگاریتم گرفتن از کدهای دسته‌ای رفع شد؛ بررسی دوباره نشان داد بهبودِ دستورهای ویژگیِ مشتق‌شده از همین حساب‌وکتاب روی کدها می‌آمد.

نقشه‌ی راه: فاز ۱ هسته‌ی اثبات (گراف گردش کار، بررسی‌کننده، ثبت حرکت‌ها، بنچمارک)؛ فاز ۲ اجرای کد و GPU و اتصال‌ها؛ فاز ۳ بسته‌های تخصصی با شروع از بینایی ماشین؛ فاز ۴ آموزش مدل کوچک و متمرکز؛ و در کنار آن پژوهش‌هایی مثل ایده‌ی «کیک».

قدم‌های بعدی: در صفحه‌ی Blueprint برای هر قابلیت Must، Later یا Cut بزنید؛ به سؤال‌های برگه‌ی مالک (لحظه‌ی پیش‌بینی HyperAck و پنجره‌ی خروج مشتری Telco) جواب دهید؛ و ساخت را از گراف گردش کار و بررسی‌کننده‌ی آن شروع کنیم. پیش از آن، دو تست شکست‌خورده باید درست شوند و طراحی جدید دمو commit شود.

دمو، بخش به بخش

ساختار کلی. منوی کناری چهار گروه دارد. هر صفحه با تب «Overview» باز می‌شود: چهار عدد اصلی و یک کارت اصلی. جزئیات در تب‌های بالای صفحه است. در نوار بالا مسیر صفحه، جست‌وجو (⌘K)، انتخاب نما (توسعه‌دهنده، کسب‌وکار، پژوهشگر، مدیر) و تغییر تم هست. پایین منو، لایه‌ی Blueprint (نشان می‌دهد هر قابلیت امروز ساخته شده یا نه) و تورهای راهنما قرار دارند. اعدادی که کنارشان برچسبی مثل `EXP-010` دارند واقعی‌اند؛ بقیه داده‌ی نمونه است.

۱. فضای کاری (Workspace)

- **Home:** خلاصه‌ی فضای کاری: ۹ ستون نشتی پیش از آموزش مسدود شده، هر ۶ holdout فقط یک بار باز شده، ۴ حرکت ناامن متوقف شده و هزینه‌ی این ماه. کادر «از یک جمله شروع کن» و فهرست کارهایی که منتظر شماست. تب‌ها: Projects (۸ پروژه) و Activity.
- **New project:** جادوی شش‌مرحله‌ای از هدف تا قرارداد امضاشده؛ تا قرارداد امضا نشود، هیچ مدلی آموزش نمی‌بیند. تب Data profile پروفایل ستون‌ها و منبع داده را نشان می‌دهد.
- **Intern:** گفت‌وگو با اینترن که در یک بودجه‌ی مشخص (تعداد ابزار، زمان، هزینه) کار می‌کند و هر جا فقط مالک جواب را می‌داند، می‌ایستد و می‌پرسد. تب‌ها: Sessions، Guardrails و Model tiers.
- **Compute & jobs:** کارهای در حال اجرا، ساعت GPU و هزینه، با سقف بودجه. تب‌ها: Spend & approvals و Where it runs.

۲. پروژه‌ی نمونه: تماس‌های سپرده‌ی مدت‌دار (Term deposits)

این پروژه مسیر واقعی آزمایش‌های EXP-006 تا EXP-010 روی داده‌ی bank marketing را دنبال می‌کند.

- **Workflow:** گراف ده‌مرحله‌ای WF-01 تا WF-10، حرکت‌های مجاز بین مرحله‌ها و یک حرکت ناامن که مسدود شد. می‌توان بین سه پروژه (Term-deposit، HyperAck، Telco) جابه‌جا شد. تب‌ها: Transition log (ثبت همه‌ی حرکت‌ها) و Validator & team.
- **Contract & data:** قرارداد پیش‌بینی: سؤال، لحظه‌ی پیش‌بینی، ستون ممنوع `duration` (فقط بعد از پایان تماس معلوم است)، ظرفیت ۲٬۰۰۰ تماس در ماه، ۸€ هزینه‌ی هر تماس و ۱۱۰€ ارزش هر اشتراک. تب‌ها: Known، Owner questions، when (خط زمانی ستون‌ها)، Costs & metric و Data & split.
- **Notebook:** نوت‌بوک یک همکار که دقت ۰٫۹۶۸۹ نشان می‌دهد، با یک همراه (companion) که ۱۰ یافته‌ی واقعیِ copilot را کنار هر سلول می‌گذارد. بعد از اصلاح‌ها، امتیاز صادقانه ROC-AUC ۰٫۷۵۷۷ است. تب‌ها: Outline & variables، Clean version، Precedents و Stage cells.
- **Leakage & features:** ماتریس ۱۶ ستون: هر ستون در لحظه‌ی پیش‌بینی معلوم است یا نه. تب‌ها: Leak checks (با `duration` امتیاز از ۰٫۷۱۳۰ به ۰٫۸۹۷۲ می‌پرد)، Feature ladder، Data look و Critic review.
- **Models:** پنج خانواده‌ی مدل روی foldهای یکسان، با قانون انتخابی که از قبل اعلام شده بود؛ extra_trees انتخاب شد. تب‌ها: Tuning، Selection rule و Cost & context.
- **Reliability:** داده‌ی holdout فقط یک بار باز شد: ROC-AUC ۰٫۷۷۱۸ با بازه‌ی ۰٫۷۱۲۶ تا ۰٫۸۲۹۰، و دروازه‌ی تولید ۲ از ۶. تب‌ها: Shift & missing، Calibration & slices، Operating points و Production gate.

- **Decision brief:** گزارش یک‌صفحه‌ای برای تصمیم‌گیران، به انگلیسی و فارسی: حدود ۷۸۰ اشتراک و حدود €۷۰,۰۰۰ ارزش خالص، با پیشنهاد یک پایلوت. تب‌ها: Risks، Value calculator و Sign-off & lessons.

۳. دانش (Knowledge)

- **Evidence library:** جست‌وجو در ۱۳۳ رکورد واقعی مخزن (قانون، آزمایش، نشت، دام). تب‌ها: Rules & workflow، Ask، Datasets و What's inside.
- **Research lab:** در مجموع ۵۷۹ آزمایش، کمپین‌ها، دروازه‌ی منتقد (۱۵۷ چالش، ۱۴۷ نگه‌داشته) و ۶۱٪ recall ممیز کور. تب‌ها: Critic gate، Pitfalls، Champions و Research map.
- **Benchmark:** سنجش قضاوت ایجنت: ممیز کور ۱۱ از ۱۸ نشت را پیدا کرد، پایلوت نوت‌بوک ۶ از ۷. جدول رده‌بندی هنوز برنامه‌ریزی‌شده است.
- **Policy model:** مدل کوچک و متمرکز: ۳۲۶ نمونه‌ی آموزشی و برنامه‌ی آموزشی چهارمرحله‌ای (فقط مرحله‌ی اول داده دارد). تب‌ها: Expert review، Training data و Training & serving.

۴. پلتفرم (Platform)

- **Domain packs:** هشت بسته روی یک موتور: جدولی آماده است؛ سری زمانی، بینایی ماشین، رانندگی، نقشه و … در مراحل بعدی. تب Ten steps mapped نشان می‌دهد ده مرحله در هر حوزه چه معنایی دارد.
- **Integrations:** سرور MCP با ۱۸ ابزار (۳۲ ابزار در حالت ML Intern)، API، VS Code، Chat UI و اتصال‌های داده.
- **Admin:** ده سیاست که چهار تا قفل‌اند (مثل «holdout فقط یک بار باز می‌شود»)، ۵ نقش، مسیریابی مدل‌ها، بودجه و audit log.
- **Blueprint & roadmap:** در مجموع ۱۵۱ قابلیت: ۵۱ ساخته‌شده، ۴۶ نیمه‌کاره، ۴۸ برای ساخت و ۶ نیازمند پژوهش. تب‌ها: Roadmap، Decisions (برای هر قابلیت Later، Must یا Cut بزنید) و Scope.