THE SEALED EXAM, A SECOND LOOK

Three markers, one set of papers

You, the exam's judge, and a second Opus agent you ran each marked the same 10 sealed papers. Here is who agrees with whom, and what it means.

امتحان مُهروموم‌شده، نگاه دوم

سه نمره‌دهنده، یک دسته برگه

شما، داور امتحان، و یک عامل Opus دوم که خودتان اجرا کردید، هر سه همان ۱۰ برگه را نمره دادید. این‌جا می‌بینید چه کسی با چه کسی هم‌نظر است و معنی‌اش چیست.

1 · WHO AGREES WITH WHOM

The two models agree with each other, not with you

Pair	Agreement
Judge and second Opus	**89%**
Second Opus and you	69%
Judge and you	66%

Like two teachers from the same school marking alike, while the parent who reads the paper marks more kindly.

۱ · چه کسی با چه کسی هم‌نظر است

دو مدل با هم هم‌نظرند، نه با شما

جفت	هم‌نظری
داور و Opus دوم	**89%**
Opus دوم و شما	69%
داور و شما	66%

مثل دو معلم از یک مدرسه که شبیه هم نمره می‌دهند، در حالی که پدر یا مادری که برگه را می‌خواند مهربان‌تر نمره می‌دهد.

2 · MARKS FOR EACH STUDENT

"Did it understand?" in the 10 papers

۲ · نمره‌ی هر دانش‌آموز

«آیا فهمید؟» در ۱۰ برگه

Student	You	Second Opus	Judge
Old Home (3)	0.75	0.08	0.17
Claude alone (3)	0.92	0.67	0.67
Lead agent (4)	0.80	0.87	0.87

The second Opus gives almost the same marks as the judge. By their marks, the lead agent leads. By yours, Claude alone leads.

دانش‌آموز	شما	Opus دوم	داور
Home قدیمی (۳)	0.75	0.08	0.17
Claude تنها (۳)	0.92	0.67	0.67
دستیار اصلی (۴)	0.80	0.87	0.87

Opus دوم تقریباً همان نمره‌های داور را می‌دهد. با نمره‌های آن‌ها، دستیار اصلی جلوست. با نمره‌های شما، Claude تنها جلوست.

3 · WHAT IT MEANS

The judge is not broken. You and the models use different rules.

The judge is not marking at random: another Opus marks the same way. The gap is about what "understood" means.

- **You** give the point when the assistant got the gist.
- **The models** give it only when the assistant showed it clearly: said it back, or acted on it.

A student writes "about ten" and the answer is exactly 10. You give the point. The models do not.

The second Opus also spotted two places where you may have clicked the wrong button. Even if those are fixed, you and the judge agree 68%, still under 70%.

۳ · معنی‌اش چیست

داور خراب نیست. شما و مدل‌ها قانون متفاوتی دارید.

داور تصادفی نمره نمی‌دهد: یک Opus دیگر هم همان‌طور نمره می‌دهد. اختلاف سر معنی «فهمیدن» است.

- **شما** وقتی امتیاز می‌دهید که دستیار اصل مطلب را گرفته باشد.
- **مدل‌ها** فقط وقتی امتیاز می‌دهند که دستیار آن را واضح نشان داده باشد: یا تکرارش کرده، یا بر اساسش عمل کرده.

دانش‌آموز می‌نویسد «حدود ده» و جواب دقیقاً ۱۰ است. شما امتیاز می‌دهید. مدل‌ها نمی‌دهند.

Opus دوم دو جا هم پیدا کرد که شاید دکمه را اشتباه زده باشید. حتی اگر آن دو درست شوند، هم‌نظری شما و داور 68% است؛ هنوز زیر 70%.

4 · LIMITS

Why two models agreeing does not make them right

- The judge and the second marker are both Opus. Models from one family can share the same habits, so their agreement proves they are consistent, not that they are correct.
- Only 10 papers, three or four per student. One paper can move a mark a lot.
- You said you were not fully sure.

۴ · محدودیت‌ها

چرا هم‌نظری دو مدل یعنی درست بودنشان نیست

- داور و نمره‌دهنده‌ی دوم هر دو Opus هستند. مدل‌های یک خانواده ممکن است عادت‌های مشترک داشته باشند؛ پس هم‌نظری‌شان نشان می‌دهد ثابت‌قدم‌اند، نه این‌که درست می‌گویند.
- فقط ۱۰ برگه؛ برای هر دانش‌آموز سه یا چهار برگه. یک برگه می‌تواند نمره را خیلی جابه‌جا کند.
- خودتان گفتید کاملاً مطمئن نبودید.

5 · THE VERDICT

The result stays "fail"

The rule, written before the exam, said **you** are the reference. Changing the reference now, after seeing the scores, would be like changing how an exam is marked after reading the results. So the verdict stays fail. fail

۵ · حکم

نتیجه «رد» می‌ماند

قانونی که قبل از امتحان نوشتیم می‌گفت معیار **شما** هستید. عوض کردن معیار حالا، بعد از دیدن نمره‌ها، مثل این است که بعد از دیدن نتیجه‌ها روش نمره‌دادن را عوض کنیم. پس حکم «رد» می‌ماند. رد

6 · WHAT I RECOMMEND

Agree on one meaning of "understood", then measure again

1. **Write the rule down**, with examples. My suggestion: a point counts only when the assistant **said it back or acted on it**. That is the stricter rule. It fits DCLab because the person must see what was understood to correct it.
2. You mark about 20 **practice** papers with that rule, and I tune the judge until it agrees with you.
3. A new sealed set, written by someone else, opened once.

۶ · پیشنهاد من

روی یک معنی برای «فهمیدن» توافق کنیم، بعد دوباره اندازه بگیریم

1. **قانون را با مثال بنویسیم.** پیشنهاد من: یک نکته فقط وقتی حساب می‌شود که دستیار **آن را تکرار کرده یا بر اساسش عمل کرده** باشد. این قانون سخت‌گیرتر است. به DCLab می‌خورد، چون آدم باید ببیند دستیار چه فهمیده تا بتواند اصلاحش کند.

2. شما حدود ۲۰ برگه‌ی **تمرینی** را با همین قانون نمره می‌دهید و من داور را تنظیم می‌کنم تا با شما هم‌نظر شود.
3. یک امتحان مُهروموم‌شده‌ی تازه، نوشته‌ی کس دیگر، که فقط یک بار باز می‌شود.

اگر قانون سخت‌گیرتر را انتخاب کنید، هر دو مدل همین حالا می‌گویند دستیار اصلی جلوست (0.87 در برابر 0.67). اگر قانون مهربان‌تر را انتخاب کنید، هنوز جلو نیست و کار باید روی خود دستیار انجام شود، نه داور.

If you choose the stricter rule, both models already say the lead agent leads (0.87 against 0.67). If you choose the kinder rule, it does not lead yet, and the work is on the agent, not the judge.