HEAD TO HEAD · SAME PEOPLE, SAME MODEL

Lead agent vs Claude alone

Both students are the same Claude model (Sonnet 5.5) with the same table tools. The only difference is DCLab's harness around the lead agent: the case file, the code checks and its instructions. Each person met both, so every result is a fair pair.

رودررو · همان آدم‌ها، همان مدل

دستیار اصلی در برابر Claude تنها

هر دو دانش‌آموز همان مدل Claude هستند (Sonnet 5.5) با همان ابزارهای جدول. تنها تفاوت، چارچوب DCLab دور دستیار اصلی است: پرونده، بررسی‌های کد و دستورهایش. هر آدم با هر دو صحبت کرد، پس هر نتیجه یک جفت منصفانه است.

THE SHORT ANSWER

Safer and understands better; slower and costs more

- **Clearly better, counted by code:** it never invents numbers. Claude alone stated numbers nobody gave in 27 of 40 sealed conversations.
- **Better by the judge's marks:** understanding (+0.23), option fit (+1.6 of 5), traps caught (+37 points).
- **The same:** it reaches the right kind of help as often (0.90 both).
- **Worse:** about 7 seconds slower per reply, about 0.09 euro more per person, and it asks again about things the person already said more often.

An invented number looks like "about 14% of your customers leave" when nobody calculated it. For a business decision, that is the most dangerous kind of mistake.

جواب کوتاه

ایمن‌تر است و بهتر می‌فهمد؛ کُندتر و گران‌تر است

- **به‌روشنی بهتر، شمرده‌شده با کد:** هیچ‌وقت عدد نمی‌سازد. Claude تنها در ۲۷ گفتگو از ۴۰ گفتگوی مُهروموم‌شده عددی گفت که کسی نداده بود.
- **بهتر با نمره‌ی داور:** فهمیدن (+0.23)، تناسب گزینه‌ها (+1.6 از ۵)، گرفتن تله‌ها (+37 امتیاز).
- **برابر:** به همان اندازه به نوع درست کمک می‌رسد (0.90 هر دو).
- **بدتر:** حدود ۷ ثانیه کُندتر در هر جواب، حدود 0.09 یورو گران‌تر برای هر نفر، و بیشتر درباره‌ی چیزی که آدم قبلاً گفته دوباره می‌پرسد.

یک عدد ساختگی مثل این است: «حدود ۱۴٪ مشتری‌هایتان می‌روند»، وقتی هیچ‌کس آن را حساب نکرده. برای یک تصمیم کسب‌وکار، این خطرناک‌ترین نوع اشتباه است.

NEWEST · THE SHORT LEAD AGENT

تازه‌ترین · دستیار اصلیِ کوتاه

امتحان مُهروموم‌شده‌ی دوم و جفت‌های کور

دستیار اصلی کوتاه شد (حدود ۸۰ کلمه در هر پیام)، بعد روی **۱۹ آدم تازه** که هرگز ندیده بود (CEX-017) در برابر Claude تنها امتحان شد. سپس سه مدل Claude (Opus، Sonnet، Haiku) در ۸ جفت، بدون دانستن هویت، دستیار بهتر را انتخاب کردند.

انتخاب کور	دستیار اصلی	Claude تنها	یکسان
Opus	**5**	3	0
Sonnet	**6**	1	1
Haiku	**6**	2	0
Majority · اکثریت	**6**	2	0

به‌روشنی بهتر و شمرده‌شده با کد: هیچ عدد ساختگی (Claude تنها ۱۳۹). بهتر با نمره‌ی داور: فهمیدن و گزینه‌ها. حالا سرعت برابر. بدتر: مسیر درست (0.79 در برابر 1.00) و درخواست‌های روشن، که بعد در کد تعمیر و روی آدم‌های تمرینی قبول شدند، اما هنوز روی امتحان مُهروموم‌شده‌ی تازه نه.

Second sealed exam and blind pairs

The lead agent was made short (about 80 words a message), then tested on **19 new people** it had never seen (CEX-017), against Claude alone. Then three Claude models (Opus, Sonnet, Haiku) picked blind which helper was better in 8 pairs.

Blind picks	Lead agent	Claude alone	Same
Opus	**5**	3	0
Sonnet	**6**	1	1
Haiku	**6**	2	0
Majority · اکثریت	**6**	2	0

Clearly better and counted by code: no invented numbers (Claude alone 139). Better by the judge: understanding and options. Now the same speed. Worse: the right route (0.79 vs 1.00) and clear requests, both fixed afterwards in code and passed on practice people, not yet on a new sealed set.

SEALED EXAM V2 · CEX-017 · 19 NEW PEOPLE · امتحان مُهروموم‌شده‌ی دوم

Measure معیار	**Measured by** سنجیده توسط	**Lead better · same · worse** بهتر · برابر · بدتر	**Lead agent** دستیار اصلی	**Claude alone** Claude تنها	**Difference** تفاوت	**90% range** ٪بازه‌ی ۹۰	**Winner** برنده
understanding فهمیدن	judge داور	7 · 11 · 1	0.93	0.82	+0.12	+0.04 … +0.21	**Lead agent** دستیار اصلی
option fit تناسب گزینه‌ها	judge داور	4 · 2 · 0	4.17	3.33	+0.83	+0.33 … +1.33	**Lead agent** دستیار اصلی
right route reached رسیدن به مسیر درست	code کد	0 · 15 · 4	0.79	1.00	-0.21	-0.37 … -0.05	**Claude alone** Claude تنها
trap handled گرفتن تله	judge داور	4 · 3 · 5	0.58	0.67	-0.08	-0.50 … +0.33	No clear difference تفاوت روشنی نیست
useful questions (share) سهم سؤال‌های مفید	judge داور	0 · 13 · 4	0.94	1.00	-0.06	-0.12 … -0.01	**Claude alone** Claude تنها
questions already answered سؤال درباره‌ی چیزِ گفته‌شده	judge داور	0 · 14 · 5	0.32	0.05	+0.26	+0.11 … +0.42	**Claude alone** Claude تنها
invented numbers and broken rules عدد ساختگی و قانون‌شکنی	code کد	12 · 7 · 0	0.00	7.32	-7.32	-12.42 … -3.05	**Lead agent** دستیار اصلی
seconds per reply ثانیه برای هر جواب	code کد	11 · 0 · 8	22.09	23.59	-1.50	-6.61 … +3.08	No clear difference تفاوت روشنی نیست
cost per person (EUR) هزینه برای هر نفر (یورو)	code کد	4 · 0 · 15	0.14	0.08	+0.06	+0.03 … +0.10	**Claude alone** Claude تنها

Trap · تله	Lead agent · دستیار اصلی	Claude alone · Claude تنها
clear_request	0 / 2	2 / 2
missing_column	1 / 2	1 / 2
no_outcome	2 / 2	2 / 2
real_prediction	0 / 1	1 / 1
report_not_model	2 / 2	0 / 2
rows_request	1 / 1	1 / 1
silent_drop	0 / 1	1 / 1

FIRST SEALED EXAM CEX-013 (THE LONG LEAD AGENT) · 40 PEOPLE, RUN ONCE · امتحان مُهروموم‌شده

Measure معیار	Measured by سنجیده توسط	Lead better · same · worse بهتر · برابر · بدتر	Lead agent دستیار اصلی	Claude alone Claude تنها	Difference تفاوت	90% range ٪بازه‌ی ۹۰	Winner برنده
understanding فهمیدن	judge داور	18 · 18 · 4	0.85	0.62	+0.23	+0.14 … +0.33	**Lead agent** دستیار اصلی
option fit تناسب گزینه‌ها	judge داور	10 · 0 · 0	4.20	2.60	+1.60	+1.20 … +2.00	**Lead agent** دستیار اصلی
right route reached رسیدن به مسیر درست	code کد	3 · 34 · 3	0.90	0.90	+0.00	-0.10 … +0.10	No clear difference تفاوت روشنی نیست
trap handled گرفتن تله	judge داور	7 · 12 · 0	1.00	0.63	+0.37	+0.21 … +0.53	**Lead agent** دستیار اصلی
useful questions (share) سهم سؤال‌های مفید	judge داور	4 · 15 · 13	0.87	0.95	-0.08	-0.15 … -0.00	**Claude alone** Claude تنها
questions already answered سؤال درباره‌ی چیز گفته‌شده	judge داور	4 · 23 · 13	0.42	0.10	+0.33	+0.12 … +0.55	**Claude alone** Claude تنها
invented numbers and broken rules عدد ساختگی و قانون‌شکنی	code کد	27 · 13 · 0	0.00	15.45	-15.45	-29.93 … -5.58	**Lead agent** دستیار اصلی
seconds per reply ثانیه برای هر جواب	code کد	7 · 0 · 33	33.54	26.19	+7.35	+1.33 … +12.57	**Claude alone** Claude تنها
cost per person (EUR) هزینه برای هر نفر (یورو)	code کد	6 · 0 · 34	0.20	0.12	+0.09	+0.00 … +0.15	**Claude alone** Claude تنها

"Lead better · same · worse" counts people. The 90% range shows how sure we are: when the whole range is on one side of zero, the difference is clear. · «بهتر · برابر · بدتر» آدم‌ها را می‌شمارد. بازه‌ی ۹۰٪ نشان می‌دهد چقدر مطمئنیم: وقتی کل بازه یک طرف صفر باشد، تفاوت روشن است.

TRAPS, ONE BY ONE

Where Claude alone fell

تله‌ها، یکی‌یکی

جایی که Claude تنها زمین خورد

Trap	Lead agent	Claude alone
clear_request	6 / 6	6 / 6
missing_column	3 / 3	3 / 3
no_outcome	1 / 1	1 / 1
real_prediction	2 / 2	0 / 2
report_not_model	2 / 2	1 / 2
rows_request	1 / 1	1 / 1
silent_drop	1 / 1	0 / 1
vague_goal	3 / 3	0 / 3

Claude alone missed every "vague goal" person (0 of 3): it jumped to a plan before learning the goal. It also missed the people who truly needed a prediction model (0 of 2).

تله	دستیار اصلی	Claude تنها
clear_request	6 / 6	6 / 6
missing_column	3 / 3	3 / 3
no_outcome	1 / 1	1 / 1
real_prediction	2 / 2	2 / 0
report_not_model	2 / 2	2 / 1
rows_request	1 / 1	1 / 1
silent_drop	1 / 1	1 / 0
vague_goal	3 / 3	3 / 0

Claude تنها همه‌ی آدم‌های «هدف مبهم» را از دست داد (۰ از ۳): پیش از فهمیدن هدف، سراغ برنامه رفت. آدم‌هایی را هم که واقعاً مدل پیش‌بینی لازم داشتند از دست داد (۰ از ۲).

PRACTICE RUN CEX-009 · 41 PEOPLE · THE SAME PATTERN · اجرای تمرینی، همان الگو

Measure معیار	Measured by سنجیده توسط	Lead better · same · worse بهتر · برابر · بدتر	Lead agent دستیار اصلی	Claude alone Claude تنها	Difference تفاوت	90% range بازه‌ی ۹۰٪	Winner برنده
understanding فهمیدن	judge داور	25 · 16 · 0	0.88	0.52	+0.36	+0.28 … +0.44	**Lead agent** دستیار اصلی
option fit تناسب گزینه‌ها	judge داور	11 · 0 · 2	4.08	3.08	+1.00	+0.54 … +1.38	**Lead agent** دستیار اصلی
right route reached رسیدن به مسیر درست	code کد	3 · 33 · 5	0.73	0.78	-0.05	-0.17 … +0.07	No clear difference تفاوت روشنی نیست
trap handled گرفتن تله	judge داور	7 · 12 · 0	0.95	0.58	+0.37	+0.21 … +0.53	**Lead agent** دستیار اصلی
useful questions (share) سهم سؤال‌های مفید	judge داور	4 · 15 · 4	0.91	0.91	+0.00	-0.08 … +0.08	No clear difference تفاوت روشنی نیست
questions already answered سؤال درباره‌ی چیز گفته‌شده	judge داور	3 · 32 · 6	0.17	0.10	+0.07	-0.05 … +0.20	No clear difference تفاوت روشنی نیست
invented numbers and broken rules عدد ساختگی و قانون‌شکنی	code کد	8 · 33 · 0	0.00	0.80	-0.80	-1.39 … -0.29	**Lead agent** دستیار اصلی
seconds per reply ثانیه برای هر جواب	code کد	2 · 0 · 39	22.73	13.98	+8.76	+6.06 … +11.10	**Claude alone** Claude تنها
cost per person (EUR) هزینه برای هر نفر (یورو)	code کد	0 · 0 · 41	0.10	0.02	+0.08	+0.07 … +0.10	**Claude alone** Claude تنها

HOW SURE ARE WE?

Trust the code's numbers now; the judge's after your marks

Counted by code (trustworthy now): right route, invented numbers, seconds, cost.

Marked by the judge (not yet trusted): understanding, option fit, traps, useful and repeated questions. The judge agreed with you only 66% of the time on the sealed papers.

چقدر مطمئنیم؟

به عددهای کد همین حالا اعتماد کنید؛ به نمره‌های داور بعد از نمره‌های شما

شمرده‌شده با کد (همین حالا قابل اعتماد): مسیر درست، عدد ساختگی، ثانیه، هزینه.

نمره‌ی داور (هنوز قابل اعتماد نیست): فهمیدن، تناسب گزینه‌ها، تله‌ها، سؤال‌های مفید و تکراری. داور روی برگه‌های مُهروموم‌شده فقط 66% با شما هم‌نظر بود.

So today we can say for sure: the lead agent is safer, as good at the route, slower and dearer. "It understands better" becomes sure once the judge agrees with your marks on the 20 practice papers.

پس امروز با اطمینان می‌گوییم: دستیار اصلی ایمن‌تر است، در مسیر به همان خوبی است، کُندتر و گران‌تر است. «بهتر می‌فهمد» وقتی قطعی می‌شود که داور با نمره‌های شما روی ۲۰ برگه‌ی تمرینی هم‌نظر شود.