PHASE 13 · 31 OCTOBER · THE CONCLUSION

Where we are, in one page

What we learned, what is decided, what is running, and what waits for you.

فاز ۱۳ · ۳۱ اکتبر · جمع‌بندی

کجا هستیم، در یک صفحه

چه یاد گرفتیم، چه تصمیمی گرفته شد، چه چیزی در حال اجراست، و چه چیزی منتظر شماست.

1 · THE SHORT ANSWER

The lead agent is better, but not proven yet

The new lead agent understands people better than the old Home and than Claude alone, by the judge's marks. It never invents numbers and catches every trap. But the judge agrees with you only 66% of the time, so we cannot call it proven. It is not switched on yet.

Like a new student with top marks from one teacher, when the head teacher marked a few papers differently. First we agree on how to mark, then we test again.

۱ · جواب کوتاه

دستیار اصلی بهتر است، اما هنوز ثابت نشده

با نمره‌های داور، دستیار اصلی تازه آدم‌ها را بهتر از Home قدیمی و بهتر از Claude تنها می‌فهمد. هیچ‌وقت عدد نمی‌سازد و همه‌ی تله‌ها را می‌گیرد. اما داور فقط 66% با شما هم‌نظر است، پس نمی‌توانیم بگوییم ثابت شده. هنوز روشن نشده است.

مثل دانش‌آموز تازه‌ای که از یک معلم بهترین نمره را گرفته، ولی مدیر مدرسه چند برگه را جور دیگری نمره داده. اول روی روش نمره‌دادن توافق می‌کنیم، بعد دوباره امتحان می‌گیریم.

2 · WHAT WE LEARNED

Five lessons

1. **The judge is consistent.** A second Opus marked like the judge (89%). The gap is about what "understood" means. You chose the stricter meaning: shown clearly.
2. **The lead agent is safe.** 0 invented numbers and every trap caught, checked by code, not by the judge.

۲ · چه یاد گرفتیم

پنج درس

1. **داور ثابت‌قدم است.** یک Opus دوم مثل داور نمره داد (89%). اختلاف سر معنی «فهمیدن» است. شما معنی سخت‌گیرتر را انتخاب کردید: واضح نشان داده شود.

3. **It is slow.** About 32 seconds per reply. My attempt to fix it made the route worse, so I undid it.
4. **Code limits help.** They made a practice run 20% cheaper with the same quality, and they stay.
5. **Storing needed care.** Three leaks of the sealed exam into the store were found and closed before anything left your Mac.

2. **دستیار اصلی ایمن است.** هیچ عدد ساختگی و همه‌ی تله‌ها گرفته شد؛ این‌ها را کد بررسی کرد، نه داور.
3. **کُند است.** حدود ۳۲ ثانیه برای هر جواب. تلاش من برای تندتر کردنش مسیر را بدتر کرد، پس برش گرداندم.
4. **محدودیت‌های کد کمک می‌کنند.** یک اجرای تمرینی را با همان کیفیت 20% ارزان‌تر کردند، و می‌مانند.
5. **ذخیره‌سازی دقت لازم داشت.** سه نشت امتحان مُهروموم‌شده به ذخیره پیدا و بسته شد، پیش از آن‌که چیزی از مک شما بیرون برود.

3 · WHAT IS STORED

Everything, for all seven models

- Every exam conversation, every model call and its thinking summary, kept whole.
- The results and labels of all 66 exam campaigns, practice runs whole, sealed ones as numbers only.
- Exam rows in every model's training sets: m1 2,224 · m2 405 · m3 947 · m4 1,167 · m5 4 · m6 47 · m7 judges 201 · m7 routing 328.
- On your Mac and in your private GitHub repository. The sealed exam stays only on your Mac, in its locked vault.
- A benchmark of every run, rebuilt by one command.

۳ · چه چیزی ذخیره شده

همه‌چیز، برای هر هفت مدل

- هر گفتگوی امتحان، هر درخواست به مدل و خلاصه‌ی فکرش، کامل.
- نتیجه‌ها و برچسب‌های هر ۶۶ مجموعه‌ی امتحان؛ تمرینی‌ها کامل، مُهروموم‌شده‌ها فقط عدد.
- سطرهای امتحان در مجموعه‌ی آموزشی هر مدل: m1 2,224 · m2 405 · m3 947 · m4 1,167 · m5 4 · m6 47 · m7 judges 201 · m7 routing 328.
- روی مک شما و در مخزن خصوصی GitHub شما. امتحان مُهروموم‌شده فقط روی مک، در گاوصندوق قفل‌شده می‌ماند.
- جدول مقایسه‌ی همه‌ی اجراها، که با یک فرمان دوباره ساخته می‌شود.

4 · RUNNING NOW

The full capture

۴ · در حال اجرا

Full capture

The full capture is running alone on your Mac: the store, the routing sets, the training lake, GLiNER's answers on every test, and a permanent snapshot. When it ends, I check nothing sealed is in the store and push the records to GitHub.

ذخیره‌سازی کامل

ذخیره‌سازی کامل به‌تنهایی روی مک شما در حال اجراست: انبار داده، مجموعه‌های مسیریابی، دریاچه‌ی آموزشی، جواب‌های GLiNER روی هر آزمون، و یک نسخه‌ی دائمی. وقتی تمام شد، بررسی می‌کنم چیز مُهروموم‌شده‌ای در انبار نباشد و داده‌ها را به GitHub می‌فرستم.

5 · NEXT, AND MONEY

About €12 left: only what decides something

1. **You:** mark the 20 practice papers on the desk with the strict rule. Free.
2. **Me:** compare the judge with your marks. Free. Re-mark with an adjusted judge only if needed (about €0.60).
3. **Me:** a small new sealed exam, 20 people, the lead agent and Claude alone (about €6–7).
4. **You decide:** if it passes, the lead agent becomes the real Home.

Also open for you: make the labelling desk private (its Share menu), and whether to release the old sealed exam into training once the new one exists.

۵ · قدم بعدی، و هزینه

حدود €12 مانده: فقط چیزی که تصمیم‌ساز است

1. **شما:** ۲۰ برگه‌ی تمرینی روی میز را با قانون سخت‌گیرانه نمره بدهید. رایگان.
2. **من:** داور را با نمره‌های شما مقایسه می‌کنم. رایگان. فقط اگر لازم شد، با داور تنظیم‌شده دوباره نمره می‌دهم (حدود €0.60).
3. **من:** یک امتحان مُهروموم‌شده‌ی کوچک تازه، ۲۰ آدم، دستیار اصلی و Claude تنها (حدود €6–7).
4. **تصمیم با شما:** اگر قبول شد، دستیار اصلی Home واقعی می‌شود.

کارهای باز دیگر برای شما: میز برچسب‌زنی را خصوصی کنید (منوی Share)، و تصمیم بگیرید که بعد از آمدن امتحان تازه، امتحان مُهروموم‌شده‌ی قدیمی وارد آموزش شود یا نه.